Kandidatuppsats i Statistik

Tidserieanalys av konsumentprisindex i Sverige och Tyskland

Zerui Wang
Viet Tien Trinh

Avdelningen för Statistik och maskininlärning
Institutionen för datavetenskap
Linköpings universitet

Vårterminen, 2025

Innehåll

1 Introduktion **1**
1.1 Bakgrund . . . 1
1.2 Syfte . . . 2
1.3 Frågeställning . . . 2

2 Data **3**
2.1 Databeskrivning . . . 3
2.2 Bortfall . . . 3
2.3 Visualisering av tidsserierna . . . 4
2.4 Datauppdelning . . . 5

3 Metoder **6**
3.1 Beräkning av inflation från HICP-index . . . 6
3.2 STL-dekomposition . . . 6
3.3 Tidsserieregression (TSLM) . . . 7
3.4 ACF och PACF . . . 7
3.5 Exponentiel utjämning . . . 7
3.6 ARIMA/SARIMA . . . 8
3.7 Regression med ARIMA-fel . . . 10
3.8 Rullande korsvalidering (rolling-origin cross-validation) . . . 10
3.9 Root Mean Squared Error (RMSE) . . . 10
3.10 Mean Absolute Error (MAE) . . . 11
3.11 Prognos . . . 11

4 Resultat **12**
4.1 Trend och Säsong . . . 12
4.2 Modeller . . . 14
4.3 Jämförelse . . . 16
4.4 Bäst modell . . . 17
4.5 Prognos . . . 19

5 Diskusion **20**

6 slutsat **21**

7 Bilaga **23**

1. Introduktion

I denna studie undersöka vi om genomsnittlig prisutvekcling under 2010 – 2025 för Sverige och Tyskland.

1.1 Bakgrund

Hushållskonsumtion utgör en central komponent i analysen av en nations ekonomi. Den mäts som de utgifter som hushåll gör för varor och tjänster i syfte att tillfredsställa löpande behov. Enligt SCB (Statistiska centralbyrån) utgör konsumtionen en betydande andel av bruttonationalprodukten (BNP), vilket har motiverat utvecklingen av särskilda indikatorer för att möjliggöra en noggrann uppföljning av dess kortsiktiga fluktuationer (SCB).

Ur ett makroekonomiskt perspektiv har förändringar i hushållskonsumtionen omedelbara effekter på ekonomin. En ökande konsumtionsutveckling stimulerar exempelvis produktion, sysselsättning och inkomster, medan en svag konsumtionsutveckling kan hämma den ekonomiska tillväxten (Ekonomifakta).

Harmonised Index of Consumer Prices (HICP) är ett standardiserat inflationsmått som används inom Europeiska unionen för att analysera konsumtionens utveckling i reala termer. Enligt SCB är HICP ett prisindex som utvecklats av EU:s statistikorgan Eurostat i samarbete med de nationella statistikmyndigheterna i medlemsländerna. HICP används främst som (1) målvariabel för Europeiska centralbankens (ECB) penningpolitik, (2) ett internationellt jämförbart mått på inflation samt (3) underlag för utvärdering av konvergenskriteriet avseende prisstabilitet. Indexet publiceras månadsvis av SCB och beräknas som ett kedjeindex med basår 2015 (SCB).

Sverige och Tyskland är båda högutvecklade och höginkomstländer inom Europeiska unionen (EU). Trots dessa likheter föreligger betydande skillnader i deras institutionella och ekonomiska strukturer. En central skillnad är den penningpolitiska regimen: Tyskland är en del av euroområdet och omfattas därmed av ECB:s penningpolitik, medan Sverige, med egen valuta och flytande växelkurs, bedriver en självständig penningpolitik genom Sveriges Riksbank. Mot denna bakgrund är det både intressant och relevant att genomföra en jämförande analys av inflationen i dessa två länder.

Inflation definieras som en generell ökning av den allmänna prisnivån i ekonomin, vilket innebär att varor och tjänster blir dyrare över tid (Ekonomifakta). Såväl hög som låg inflation kan skapa osäkerhet och leda till återhållsamhet i investeringar. Låg inflation kan medföra risk för deflationstryck och ett svagt investeringsklimat, medan hög inflation kan påverka ekonomins tillväxtmöjligheter negativt genom minskad förutsägbarhet (Ekonomifakta). Under september uppgick den genomsnittliga inflationstakten i flera EU-länder till 2,6 procent, med stora variationer mellan medlemsstaterna. Turkiet noterade den högsta inflationen på 33,3 procent, medan Sverige och Tyskland uppvisade inflationstal på 3,2 respektive 2,4 procent. Schweiz hade samtidigt den lägsta inflationen, uppgående till 0 procent (Ekonomifakta).

1.2 Syfte

Syftet med studien är att analysera och prognostisera inflationen i Sverige och Tyskland baserat på HICP-data för perioden 2010–2025 samt att jämföra prognosförmågan hos olika tidsseriemodeller.

1.3 Frågeställning

· Vilken av de tillämpade tidsseriemodellerna uppvisar bäst prediktionsförmåga vid prognostisering av inflationen i Sverige och Tyskland, baserat på en jämförande utvärdering av prognosfelmått (RMSE och MAE)?

2. Data

I detta kapitel presenteras en detaljerad beskrivning av de data som används i studien, inklusive deras ursprung, struktur samt hur data delas upp för analysen.

2.1 Databeskrivning

Datamaterialet som används i denna studie kommer från Eurostat: HICP – månatliga indexdata. Harmonised Index of Consumer Prices (HICP) är EU:s harmoniserade konsumentprisindex som mäter den genomsnittliga prisutvecklingen för en varu- och tjänstekorg som hushåll konsumerar. Harmoniseringen gör att måttet är jämförbart mellan länder.
I denna studie jämför vi inflationen mellan Sverige och Tyskland under 15 år (2010–2025). Eftersom år 2025 ännu inte är avslutat beaktar vi data till och med oktober 2025. Under perioden är 2015 basår, vilket innebär att indexet är normaliserat till 100 år 2015; detta följer Eurostats standard för jämförbarhet.
Efter databehandling omfattar materialet totalt 361 observationer: 181 för Tyskland (DE), motsvarande 181 månader, och 180 för Sverige (SE), motsvarande 180 månader.

Tabell 2.1: Variabler och beskrivningar

Variabel	**Beskrivning**
`Geography`	Länderna som valdes.
`TimePeriod`	Tidsperioder för analysen.
`ObsValue`	Ett mått för att mäta indexnivå för en viss period.

2.2 Bortfall

Datamaterialet innehåller varken orimliga värden eller saknade observationer. Detta ligger i linje med den kvalitetssäkring och de löpande uppdateringar som tillämpas av källan. Vi har genomfört grundliga kontroller av tidsomfång, konsekvens över månader och rimlighet i nivåförändringar. Inga brister identifierades som kräver ytterligare rensning eller imputering. Sammanfattningsvis bedöms materialet vara välstrukturerat och redo för analys.

2.3 Visualisering av tidsserierna

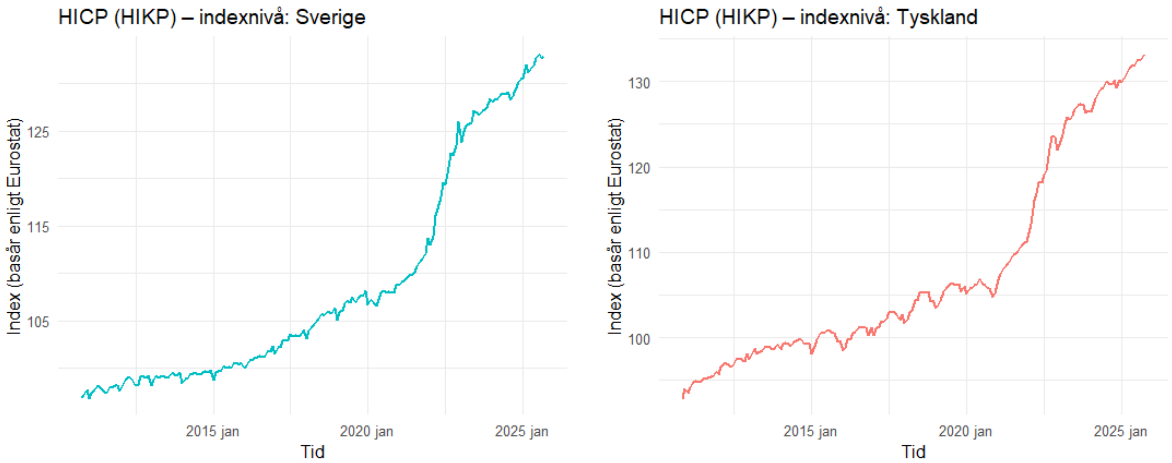

(a) HICP-indexnivå för Sverige

(b) HICP-indexnivå för Tyskland

Figur 2.1: Utvecklingen av HICP-index för Sverige och Tyskland.

Figur 2.1 visar utvecklingen av HICP-indexnivån för Sverige och Tyskland i den ursprungliga tidsserien. Figuren beskriver därmed endast de observerade data utan någon modellering eller prognos. För båda länderna kan en tydlig uppåtgående trend observeras, vilket indikerar att den allmänna prisnivån successivt har ökat över tid. Under den första delen av perioden ökar indexet relativt stabilt och gradvis, medan en tydligt snabbare ökning kan observeras under de senare åren. Mönstret är mycket likartat mellan Sverige och Tyskland, där båda länderna uppvisar en långsiktig prisökning. Denna utveckling tyder på att inflationen har ökat under den senare delen av tidsperioden och motiverar en vidare analys av inflationstakten i de efterföljande stegen.

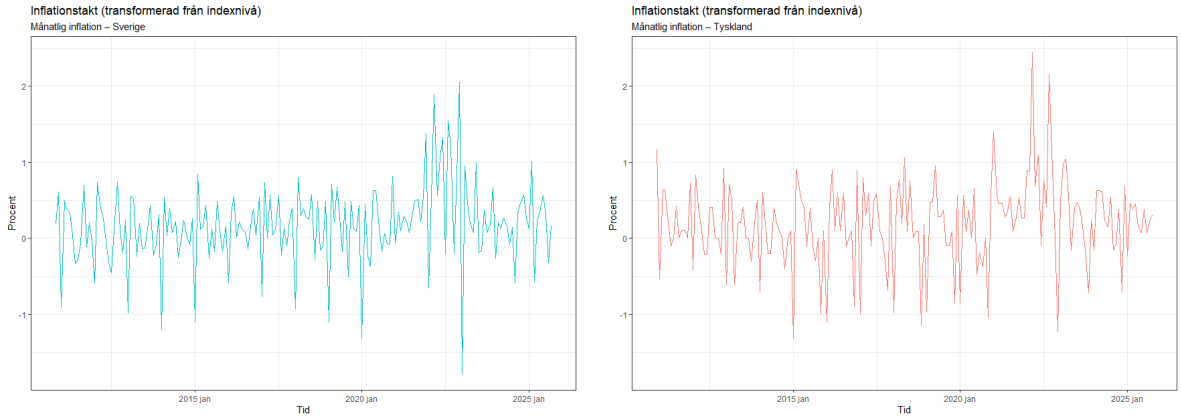

(a) Inflationen för Sverige

(b) Inflationen för Tyskland

Figur 2.2: Utvecklingen av den månatliga inflationstakten för Sverige och Tyskland.

Figur 2.2 visar utvecklingen av den månatliga inflationstakten för Sverige och Tyskland. Till skillnad från indexnivån i föregående figur fluktuerar inflationen kring ett relativt stabilt medelvärde nära noll procent per månad. Detta tyder på att transformationen från indexnivå till inflation har reducerat den långsiktiga trenden och gjort serien mer stationär. För båda länderna varierar inflationen över tid med både positiva och negativa värden, vilket innebär att prisnivån ibland ökar snabbare och ibland långsammare. Under de senare åren syns också större svängningar, särskilt kring perioden efter 2021, då flera kraftiga toppar och fall kan observeras.

2.4 Datauppdelning

Serierna delas upp i tre delmängder i kronologisk ordning för att undvika informationsläckage mellan tränings-, validerings- och testdata. Med totalt N=180 observationer och prognoshorisonten H=12 månader avsätts 3H=36 månader för validering och ytterligare 3H=36 månader för test. De återstående observationerna, motsvarande 108 månader, används som träningsdata för modellestimering. Uppdelningen genomförs separat för varje land.

Tabell 2.2: Uppdelning av data i tränings-, validerings- och testmängder

Land	Delmängd	Start	Slut	Antal obs
DE	train	2010 nov	2019 okt	108
DE	validation	2019 nov	2022 okt	36
DE	test	2022 nov	2025 okt	36
SE	train	2010 okt	2019 sep	108
SE	validation	2019 okt	2022 sep	36
SE	test	2022 okt	2025 sep	36

3. Metoder

I detta kapitel redovisas samtliga metoder och beräkningar som används i undersökningen.

3.1 Beräkning av inflation från HICP-index

Den ursprungliga tidsserien i studien består av HICP-index (Harmonised Index of Consumer Prices), vilket mäter den genomsnittliga prisutvecklingen för en konsumtionskorg av varor och tjänster över tid. För att analysera inflationen transformeras indexserien till en inflationsserie genom att beräkna den logaritmiska förändringen mellan två på varandra följande perioder.

Den månatliga inflationstakten beräknas enligt

$$infl_t = 100\,(\log(HICP_t) - \log(HICP_{t-1})) \tag{3.1}$$

där $HICP_t$ är indexnivån vid tidpunkt t. Denna transformation används ofta i ekonomisk tidsserieanalys eftersom den approximerar den procentuella förändringen i prisnivån och samtidigt bidrar till att stabilisera variansen i tidsserien.

3.2 STL-dekomposition

För att analysera tidsseriens struktur används STL-dekomposition (Seasonal-Trend decomposition using Loess). Metoden delar upp tidsserien i tre komponenter:

$$y_t = Trend_t + Season_t + Remainder_t \tag{3.2}$$

där

- $Trend_t$ beskriver den långsiktiga utvecklingen i serien,
- $Season_t$ representerar återkommande säsongsmönster,
- $Remainder_t$ är den slumpmässiga variationen som inte förklaras av trend eller säsong.

STL-metoden är särskilt användbar för månadsdata eftersom den kan identifiera säsongsmönster med period 12 och samtidigt hantera variationer i trend över tid.

3.3 Tidsserieregression (TSLM)

För att analysera om inflationen uppvisar statistiskt signifikanta trend- och säsongseffekter används en tidsserie-regressionsmodell (TSLM). I denna modell förklaras inflationen som en funktion av en trendvariabel och säsongsdummyvariabler.

Modellen kan skrivas som

$$y_t = \beta_0 + \beta_1 trend_t + season_t + \varepsilon_t \tag{3.3}$$

där

- $trend_t$ representerar den linjära tidsutvecklingen,
- $season_t$ representerar säsongseffekter för olika månader,
- ε_t är slumptermen.

Syftet med denna modell är att undersöka om inflationen uppvisar en statistiskt signifikant trend samt att identifiera systematiska säsongsmönster.

3.4 ACF och PACF

För att identifiera lämpliga ARIMA-modeller analyseras tidsseriens autokorrelationsstruktur med hjälp av ACF (Autocorrelation Function) och PACF (Partial Autocorrelation Function).

ACF mäter korrelationen mellan observationer vid olika tidsförskjutningar (laggar), medan PACF visar den direkta korrelationen mellan två observationer efter att effekten av tidigare laggar har kontrollerats.

Genom att analysera mönstren i ACF- och PACF-diagrammen kan lämpliga ordningar för ARIMA-modellen identifieras, det vill säga parametrarna p, d och q samt de säsongsrelaterade parametrarna P, D och Q.

3.5 Exponentiel utjämning

För prognoser används exponentiell utjämning, där nya observationer ges större vikt än äldre genom en geometriskt avtagande viktsfunktion. En tidsserie med trend och säsong kan modelleras med en Holt–Winters-modell, där nivå, trend och säsong uppdateras rekursivt över tiden.
I en additiva Holt-Winters-modell skrivs serien som.

$$y_t = L_t + TR_t + SN_t + e_t \tag{3.4}$$

Där

- L_t = nivå (”grundnivån” i serien vid tid t),
- TR_t = trend (hur snabbt nivån ändras),

- SN_t = säsongskomponent (t.ex. månadseffekt om $m = 12$),
- e_t = slumpfel.

I en multiplikativ Holt–Winters-modell skrivs serien som.

$$Y_t = (L_t + TR_t) \cdot SN_t + \varepsilon_t, \tag{3.5}$$

Uppdateringsformlerna (en variant) är:

- $L_t = \alpha \frac{Y_t}{S_{t-m}} + (1-\alpha)(L_{t-1} + TR_{t-1})$,
- $TR_t = \beta(L_t - L_{t-1}) + (1-\beta)TR_{t-1}$,
- $SN_t = \gamma \frac{Y_t}{L_t} + (1-\gamma)SN_{t-m}$.

där

- $\alpha, \beta, \gamma \in (0,1)$ är utjämningsparametrar som bestäms (t.ex. via minsta kvadratfel),
- L_t = uppskattad nivå,
- TR_t = uppskattad trend,
- SN_t = uppskattad säsongseffekt.

3.6 ARIMA/SARIMA

För att modellera tidsberoende strukturer i en tidsserie används ofta ARIMA- och SARIMA-modeller. Grundidén är att beskriva hur seriens aktuella värde beror på tidigare värden och tidigare slumpstörningar, efter att eventuell långsiktig trend och icke-stationaritet har tagits bort genom differenser.
En ARIMA-modell (AutoRegressive Integrated Moving Average) betecknas ARIMA(p,d,q). Här står

- p för antalet autoregressiva termer (AR),
- d för antalet differenser som används för att göra serien stationär,
- q för antalet glidande medelvärdestermer (MA).

Låt Yt vara den ursprungliga serien och Wt den differenserade serien efter d differenser. En ARIMA(p,d,q)-modell kan då skrivas som

$$W_t = c + \sum_{i=1}^{p} \phi_i W_{t-i} + \varepsilon_t + \sum_{j=1}^{q} \theta_j \varepsilon_{t-j}, \tag{3.6}$$

där

- Y_t = ursprunglig tidsserie

- $W_t = \nabla^d Y_t = d$: te differensen
- $\phi_1, \ldots, \phi_p$ = AR-parametrar
- $\theta_1, \ldots, \theta_q$ = MA-parametrar
- c = konstant (drift)
- ε_t = vit brus-felterm.

I kompakt operatorform skrivs samma modell ofta:

$$\big(1 - \phi_1 B - \cdots - \phi_p B^p\big)(1-B)^d Y_t = c + \big(1 + \theta_1 B + \cdots + \theta_q B^q\big)\varepsilon_t. \tag{3.7}$$

När tidsserien uppvisar säsongsmönster utökas modellen med säsongella komponenter, vilket ger en SARIMA-modell (Seasonal ARIMA). En sådan modell betecknas SARIMA(p,d,q)(P,D,Q)s.
Där

- (p, d, q) är de icke-säsongella delarna,
- (P, D, Q) är de säsongella autoregressiva, differens- respektive glidande medelvärdestermerna,
- s är säsongsperioden (t.ex. $s = 12$ för månadsdata).

Den generella (multiplikativa) SARIMA(p,d,q)×(P,D,Q)m kan skrivas i operatorform som

$$\Phi(B^m)\,\phi(B)\,(1-B)^d(1-B^m)^D Y_t = c + \Theta(B^m)\,\theta(B)\,\varepsilon_t, \tag{3.8}$$

Där

- B = backshift-operator ($BY_t = Y_{t-1}$)
- $\phi(B) = 1 - \phi_1 B - \cdots - \phi_p B^p$ = icke-säsongsmässig AR-del
- $\theta(B) = 1 + \theta_1 B + \cdots + \theta_q B^q$ = icke-säsongsmässig MA-del
- $\Phi(B^m) = 1 - \Phi_1 B^m - \cdots - \Phi_P B^{mP}$ = säsongsmässig AR-del
- $\Theta(B^m) = 1 + \Theta_1 B^m + \cdots + \Theta_Q B^{mQ}$ = säsongsmässig MA-del
- $(1-B)^d$ = vanliga differenser (trend)
- $(1-B^m)^D$ = säsongsdifferenser (period m, t.ex. $m = 12$ för månadsdata)
- c = konstant (drift)
- ε_t = vit brus-felterm.

3.7 Regression med ARIMA-fel

För att modellera både deterministiska komponenter och tidsberoende strukturer i inflationen används även en regressionsmodell med ARIMA-fel. I denna modell förklaras inflationen av en trendkomponent och säsongskomponenter, medan residualerna antas följa en ARIMA-process. Modellen kan skrivas som

$$y_t = \beta_0 + \beta_1 trend_t + season_t + \varepsilon_t \tag{3.9}$$

Där y_t representerar inflationen vid tidpunkt t, $trend_t$ är en trendvariabel och $season_t$ representerar säsongseffekter. Feltermen ε_t antas följa en ARIMA-process för att modellera eventuell kvarvarande autokorrelation i residualerna.

Denna modell kombinerar klassisk regressionsanalys med tidsseriemodellering och kan därför fånga både systematiska förändringar i inflationen och dynamiska beroenden över tiden.

3.8 Rullande korsvalidering (rolling-origin cross-validation)

För att jämföra prognosförmågan hos de olika modellerna används rullande korsvalidering (rolling-origin cross-validation). Tidsserien delas först upp i tränings-, validerings- och testdata i kronologisk ordning för att undvika informationsläckage mellan perioderna.

Vid varje steg skattas modellen på träningsdata och används därefter för att generera prognoser upp till en förutbestämd prognoshorisont $H = 12$ månader. Träningsfönstret flyttas sedan fram stegvis genom valideringsperioden, och nya prognoser genereras vid varje steg. På detta sätt erhålls flera prognoser för varje modell, vilket möjliggör en mer robust jämförelse av modellernas prognosprestanda.

3.9 Root Mean Squared Error (RMSE)

Root Mean Squared Error (RMSE) är ett vanligt använt mått för att utvärdera prognos- och prediktionsnoggrannhet i regressions- och tidsseriemodeller. Måttet kvantifierar den genomsnittliga storleken på prediktionsfelen genom att beräkna roten ur medelvärdet av de kvadrerade avvikelserna mellan observerade och predikterade värden.

RMSE definieras som

$$RMSE = \sqrt{\frac{1}{n}\sum_{t=1}^{n}(y_t - \hat{y}_t)^2}, \tag{3.10}$$

där

- y_t är det observerade värdet vid tidpunkt t,
- $\hat{y}_t$ är det predikterade värdet,
- n är antalet observationer.

Genom kvadreringen av felen tilldelar RMSE relativt stor vikt åt stora avvikelser, vilket innebär att måttet är särskilt känsligt för extrema prognosfel. RMSE uttrycks i samma enhet som den beroende variabeln, vilket underlättar tolkning och jämförelse mellan modeller inom samma studie.

3.10 Mean Absolute Error (MAE)

Mean Absolute Error (MAE) är ett alternativt felmått som mäter den genomsnittliga absoluta avvikelsen mellan observerade och predikterade värden. Till skillnad från RMSE baseras MAE på absoluta fel och påverkas därmed i mindre grad av enstaka stora avvikelser.

MAE definieras som

$$MAE = \frac{1}{n} \sum_{t=1}^{n} |y_t - \hat{y}_t| \,, \tag{3.11}$$

där

- y_t är det observerade värdet vid tidpunkt t,
- $\hat{y}_t$ är det predikterade värdet,
- n är antalet observationer.

MAE ger ett direkt mått på den genomsnittliga felstorleken och är lätt att tolka eftersom varje observation bidrar linjärt till det totala felet. Precis som RMSE uttrycks MAE i samma enhet som responsvariabeln.

3.11 Prognos

Efter att den bästa modellen har identifierats används modellen för att generera slutliga prognoser för inflationen. Prognoserna görs för en horisont på $H = 12$ månader framåt baserat på den skattade modellen.

För att kvantifiera osäkerheten i prognoserna beräknas även prognosintervall. I denna studie presenteras prognosintervall på 80 % och 95 %, vilket innebär att den framtida inflationen med stor sannolikhet förväntas ligga inom dessa intervall. Prognosintervallen blir bredare ju längre prognoshorisonten är, vilket speglar den ökande osäkerheten i prognoser längre fram i tiden.

4. Resultat

I detta kapitel presenteras resultaten från de statistiska analyserna och prognosmodellerna.

4.1 Trend och Säsong

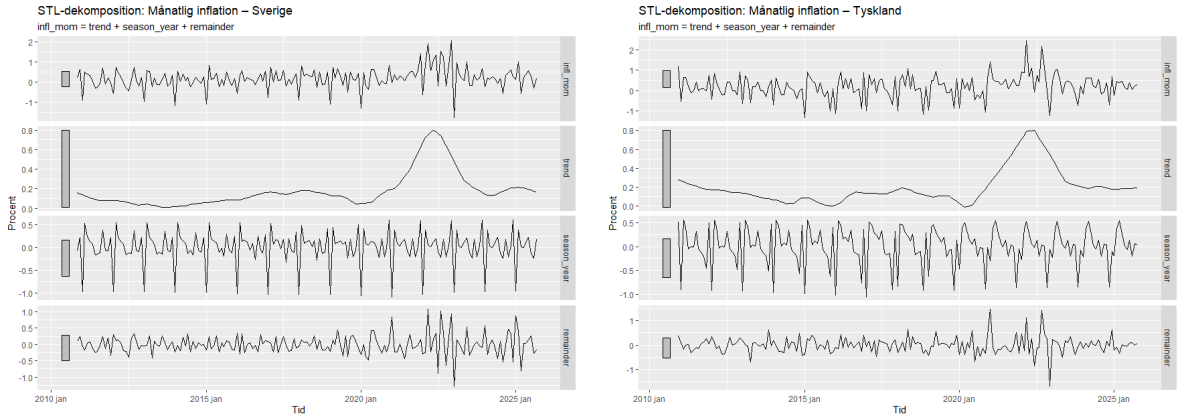

(a) Sverige

(b) Tyskland

Figur 4.1: STL-dekomposition: Månadsinflation = trend + season$_year + remainder$.

Båda länderna uppvisar liknande mönster i inflationen. STL-dekompositionen visar att inflationen består av en relativt stabil säsongskomponent och en trendkomponent som förändras över tid. Den kraftiga uppgången i trendkomponenten omkring 2021–2023 tyder på en period med hög inflation i både Sverige och Tyskland. Den oregelbundna komponenten visar att inflationen också innehåller kortsiktiga variationer som inte kan förklaras av trend eller säsong.

Resultatet visar därmed att inflationen inte är helt stationär utan påverkas av både långsiktiga förändringar och återkommande säsongsmönster.

Tabell 4.1: TSLM-koefficienter för Sverige (train). Trend är ej signifikant, medan säsongstermer är signifikanta.

Parameter	Estimate	Std Error	t	p
(Intercept)	-0.9565	0.0832	-11.500	<0.001
trend()	0.0011	0.0007	1.499	0.137
season(year2)	1.5413	0.1064	14.488	<0.001
season(year3)	1.1872	0.1064	11.159	<0.001
season(year4)	1.1852	0.1064	11.139	<0.001
season(year5)	1.0697	0.1064	10.052	<0.001
season(year6)	0.8396	0.1064	7.888	<0.001
season(year7)	0.9766	0.1065	9.173	<0.001
season(year8)	0.7695	0.1065	7.225	<0.001
season(year9)	1.3247	0.1065	12.434	<0.001
season(year10)	0.9081	0.1097	8.280	<0.001
season(year11)	0.9060	0.1064	8.516	<0.001
season(year12)	1.2359	0.1064	11.617	<0.001

Tabell 4.2: TSLM-koefficienter för Tyskland (train). Trend är ej signifikant, medan säsongstermer är signifikanta.

Parameter	Estimate	Std Error	t	p
(Intercept)	-0.8284	0.1133	-7.314	<0.001
trend()	-0.0004	0.0010	-0.407	0.685
season(year2)	1.5019	0.1449	10.367	<0.001
season(year3)	1.3961	0.1449	9.636	<0.001
season(year4)	1.0538	0.1449	7.273	<0.001
season(year5)	1.0645	0.1449	7.345	<0.001
season(year6)	0.9910	0.1449	6.837	<0.001
season(year7)	1.3123	0.1450	9.052	<0.001
season(year8)	0.8860	0.1450	6.109	<0.001
season(year9)	0.8298	0.1451	5.720	<0.001
season(year10)	0.7844	0.1451	5.405	<0.001
season(year11)	0.3840	0.1494	2.571	0.012
season(year12)	1.4371	0.1449	9.920	<0.001

I Tabell 4.1, som avser Sverige, är trendkoefficienten positiv (0.0011) men inte statistiskt signifikant ($p = 0.137$). Detta innebär att det inte finns någon tydlig linjär trend i den månatliga inflationen under träningsperioden. Däremot är samtliga säsongstermer statistiskt signifikanta ($p < 0.001$), vilket indikerar att inflationen uppvisar ett tydligt säsongsmönster där vissa månader systematiskt har högre eller lägre inflation än referensmånaden. De positiva koefficienterna tyder på att inflationen i dessa månader i genomsnitt är högre än i basmånaden.

Liknande resultat kan observeras i Tabell 4.2 för Tyskland. Trendkoefficienten är mycket liten och inte statistiskt signifikant (-0.0004, $p = 0.685$), vilket tyder på att någon tydlig långsiktig trend i infla-

tionen inte kan identifieras under träningsperioden. Däremot är nästan alla säsongstermer statistiskt signifikanta (de flesta med $p < 0.001$), vilket visar att även den tyska inflationen uppvisar ett tydligt säsongsmönster. Koefficienternas storlek varierar mellan månaderna, vilket innebär att inflationen tenderar att vara högre under vissa perioder av året.

4.2 Modeller

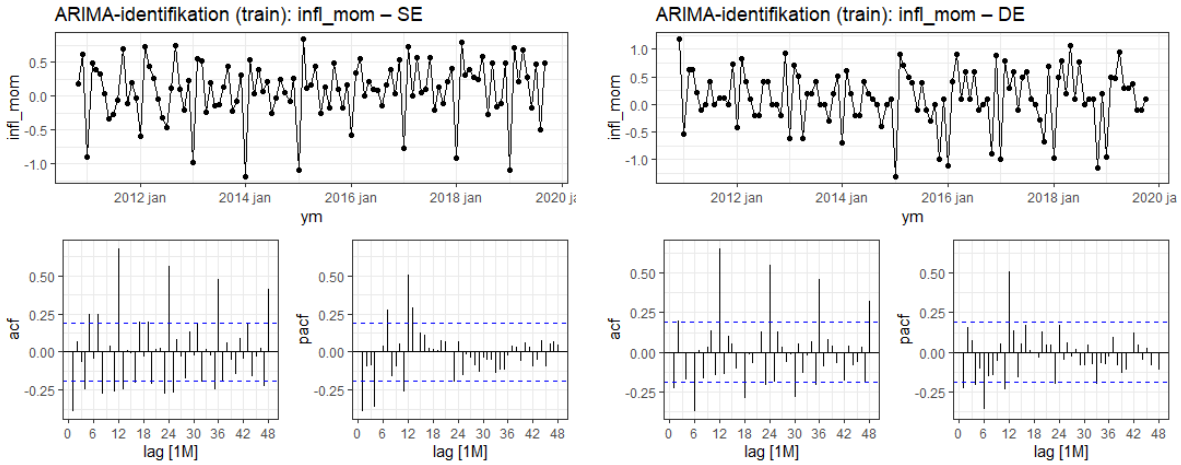

(a) Sverige

(b) Tyskland

Figur 4.2: ACF och PACF på träningsdata för inflation.

Figur a visar ACF- och PACF-diagrammen för träningsmängder används för att identifiera en lämplig ARIMA-modell för den månatliga inflationen i Sverige. Tidsserieplottet visar att serien fluktuerar kring ett relativt stabilt medelvärde utan någon tydlig trend, vilket indikerar att serien är stationär och därför inte kräver någon differensiering ($d = 0$). I ACF-diagrammet observeras tydliga spikar vid lag 12 och dess multiplar, vilket tyder på ett säsongsmönster med en period på 12 månader. Detta indikerar att en säsongskomponent bör inkluderas i modellen. PACF-diagrammet visar dessutom signifikanta spikar vid låga lag, vilket tyder på närvaron av autoregressiva komponenter. Baserat på dessa mönster anses en säsongsbetonad ARIMA-modell vara lämplig, och en modell av typen $ARIMA(3,0,0)(1,0,0)_{12}$ valdes som kandidatmodell för Sverige, eftersom den kan fånga både kortsiktiga autoregressiva effekter och säsongsvariation i inflationen.

Figur b visar tidsserie-, ACF- och PACF-diagrammen för den månatliga inflationen i Tyskland baserat på träningsdata. Tidsserieplottet visar att serien varierar kring en relativt stabil nivå utan någon tydlig trend, vilket tyder på att serien är stationär och därför inte kräver någon differensiering ($d = 0$). ACF-diagrammet uppvisar tydliga spikar vid lag 12 och dess multiplar, vilket indikerar ett säsongsmönster med en årlig periodicitet. PACF-diagrammet visar däremot svagare autoregressiva signaler vid låga lag men antyder en möjlig glidande medelvärdeskomponent. Baserat på dessa observationer valdes därför modellen $ARIMA(0,0,1)(1,0,0)_{12}$ som kandidatmodell för Tyskland.

Tabell 4.3 sammanfattar de kandidatmodeller som används för att prognostisera den månatliga inflationen (infl_mom) i studien. Tabellen visar fyra olika modeller: ETS, automatisk ARIMA, manuellt vald säsongs-ARIMA samt regressionsbaserad ARIMA. ETS-modellen bygger på exponentiell utjämning i ett state-space-ramverk, medan ARIMA_auto automatiskt väljer den mest lämpliga ARIMA- eller SARIMA-strukturen baserat på data. Den manuella ARIMA-modellen specificeras utifrån analys av ACF- och PACF-diagrammen, vilket resulterar i modellerna $ARIMA(3,0,0)(1,0,0)_{12}$ för Sverige och $ARIMA(0,0,1)(1,0,0)_{12}$ för Tyskland. Slutligen används en regressionsbaserad ARIMA-modell där inflationen modelleras som en funktion av trend- och säsongskomponenter, medan feltermen följer en ARIMA-process. Dessa modeller jämförs senare i analysen för att identifiera den modell som ger bäst prognosprestanda.

Tabell 4.3: Kandidatmodeller för prognos (infl_mom).

Modell	**Beskrivning**	**Specifikation (notation)**
ETS	Exponentiell utjämning (state-space)	ETS(infl_mom)
ARIMA_auto	Automatisk ARIMA/SARIMA-val	ARIMA(infl_mom)
ARIMA_manual	Manuellt vald säsongs-ARIMA via ACF/PACF	SE: (3,0,0)(1,0,0)[12]
		DE: (0,0,1)(1,0,0)[12]
Reg_ARIMA	Regression (trend+säsong) med ARIMA-fel	infl_mom $\sim$ trend + säsong; fel $\sim$ ARIMA

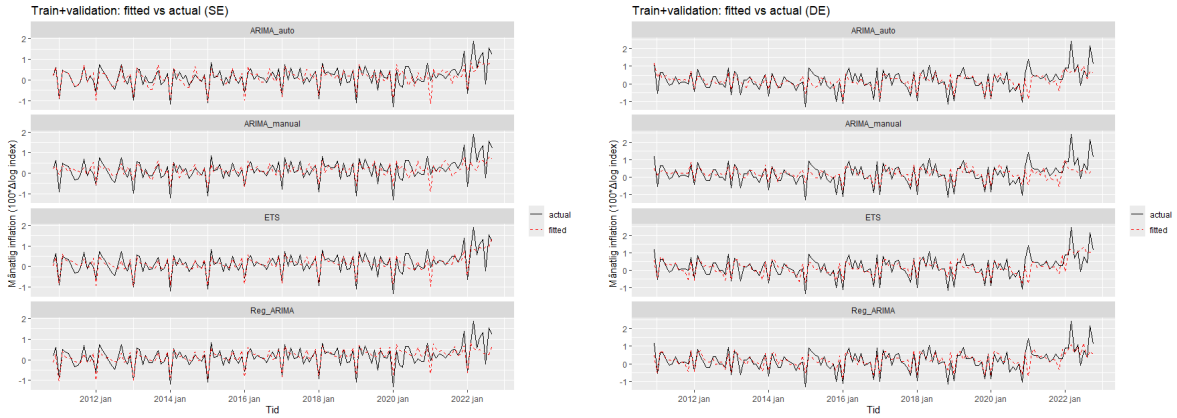

(a) Sverige

(b) Tyskland

Figur 4.3: Anpassade vs observerade värden.

För Sverige visar figuren ett liknande mönster där de skattade värdena generellt ligger nära de observerade värdena under tränings- och valideringsperioden. ARIMA-modellerna följer variationerna i inflationen relativt väl och fångar många av de kortsiktiga rörelserna i serien. ETS-modellen beskriver den övergripande utvecklingen men tenderar att vara något mer utjämnad och fångar därför inte alltid de största topparna och dalarna i inflationen. Även här syns att modellerna har svårare att exakt reproducera de kraftiga variationerna i inflationen under perioden kring 2021–2022, vilket indikerar en period med mer volatil prisutveckling.

Figuren för Tyskland visar hur de olika modellerna reproducerar den observerade månatliga inflationen under tränings- och valideringsperioden. Generellt följer de skattade värdena de faktiska observationerna relativt väl under större delen av perioden. ARIMA-modellerna fångar de kortsiktiga variationerna i inflationen något bättre än ETS-modellen, som tenderar att ge en mer utjämnad serie. Regressionsbaserad ARIMA visar också en relativt god anpassning till de observerade värdena. Mot slutet av perioden, när inflationen stiger kraftigt omkring 2022, blir skillnaderna mellan faktiska och skattade värden något större, vilket tyder på att de snabba förändringarna i inflationen är svårare för modellerna att fånga exakt.

4.3 Jämförelse

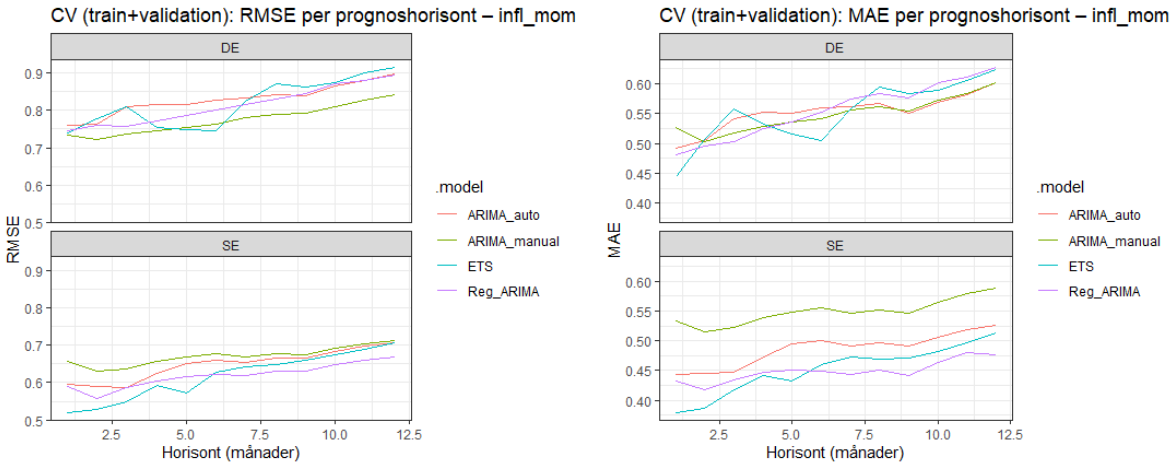

(a) Sverige

(b) Tyskland

Figur 4.4: Jämförelsen mellan kandidatmodellerna baserat på prognosfelen RMSE och MAE för olika prognoshorisonter.

Figurerna visar jämförelsen mellan kandidatmodellerna baserat på prognosfelen RMSE och MAE för olika prognoshorisonter. För Sverige ökar prognosfelen gradvis när prognoshorisonten blir längre, vilket är förväntat eftersom osäkerheten i prognoser ökar över tid. I RMSE-plottet ligger modellerna relativt nära varandra, men ETS uppvisar generellt något lägre felvärden för flera horisonter. I MAE-plottet har Reg_ARIMA och ARIMA_manual något lägre fel vid vissa horisonter, men skillnaderna mellan modellerna är små. Sammantaget indikerar resultaten att ETS-modellen ger den bästa prognosprestandan för Sverige, vilket också bekräftas av den lägsta genomsnittliga RMSE i cross-validation.

För Tyskland visar både RMSE- och MAE-plottarna att prognosfelen ökar med prognoshorisonten. I båda graferna ligger $ARIMA(0,0,1)(1,0,0)_{12}$ ofta bland de modeller som ger lägst prognosfel, särskilt vid flera medellånga och längre horisonter. De övriga modellerna – ETS, ARIMA_auto och Reg_ARIMA – uppvisar liknande men något högre felvärden. Detta tyder på att den manuellt specificerade säsongs-ARIMA-modellen bättre fångar dynamiken i den tyska inflationen. Därför valdes $ARIMA(0,0,1)(1,0,0)_{12}$ som bästa modell för Tyskland baserat på cross-validation-resultaten.

4.4 Bäst modell

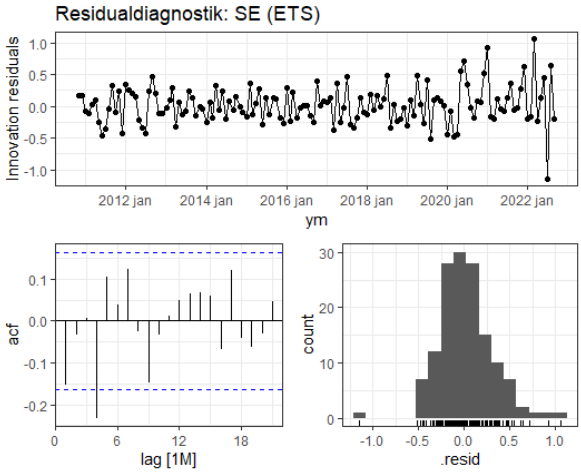

Figur 4.5: Bäst modell för Sverige serie

Residualdiagnostiken för ETS-modellen visar att residualerna fluktuerar slumpmässigt kring noll utan någon tydlig trend eller systematisk struktur över tid. ACF-diagrammet för residualerna visar att de flesta autokorrelationer ligger inom konfidensgränserna, vilket tyder på att ingen stark kvarvarande autokorrelation finns i residualerna. Histogrammet visar dessutom en relativt symmetrisk fördelning kring noll, vilket indikerar att residualerna är ungefär normalfördelade. Sammantaget tyder dessa resultat på att ETS-modellen fångar de huvudsakliga mönstren i den svenska inflationen väl och att residualerna kan betraktas som ungefär vitt brus.

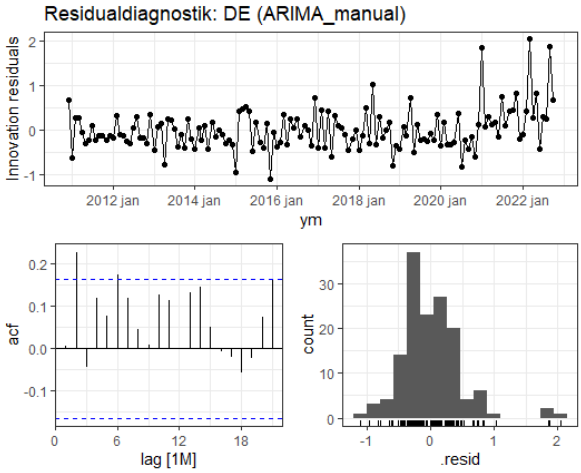

Figur 4.6: Bäst modell för Tyskland serie

Residualdiagnostiken för den manuella ARIMA-modellen visar att residualerna varierar kring noll utan någon tydlig systematisk trend över tiden. ACF-diagrammet indikerar att de flesta autokorrelationerna ligger inom konfidensgränserna, även om några mindre avvikelser kan observeras vid vissa lag. Histogrammet visar en ungefär symmetrisk fördelning kring noll, även om vissa extrema värden förekommer. Sammantaget tyder detta på att modellen fångar en stor del av tidsseriens struktur, även om vissa mindre mönster fortfarande kan finnas kvar i residualerna.

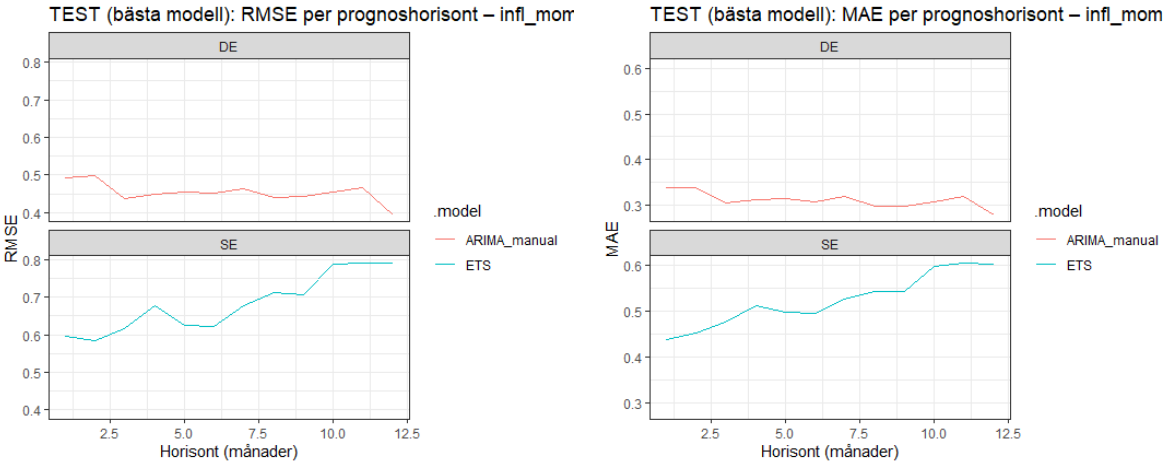

(a) Sverige

(b) Tyskland

Figur 4.7: Prognoshorison för den bäst modell.

Figuren visar prognosfelen för ETS-modellen, som valdes som bästa modell för Sverige, baserat på

testmängden. Både RMSE och MAE ökar gradvis när prognoshorisonten blir längre, vilket är förväntat eftersom osäkerheten i prognoser vanligtvis ökar med tiden. Trots denna ökning ligger felvärdena på en relativt stabil nivå över horisonterna, vilket tyder på att ETS-modellen ger rimliga och stabila prognoser för den svenska inflationen även vid längre prognoshorisonter.

För Tyskland visar figuren prognosfelen för den manuellt specificerade $ARIMA(0,0,1)(1,0,0)_{12}$. RMSE och MAE varierar något över prognoshorisonterna men ligger generellt på en relativt låg och stabil nivå. Felvärdena ökar inte lika tydligt med horisonten som i Sveriges fall, vilket indikerar att ARIMA-modellen ger relativt konsekventa prognoser över olika tidsintervall. Sammantaget tyder resultaten på att den manuella ARIMA-modellen ger god prognosprestanda för den tyska inflationen.

4.5 Prognos

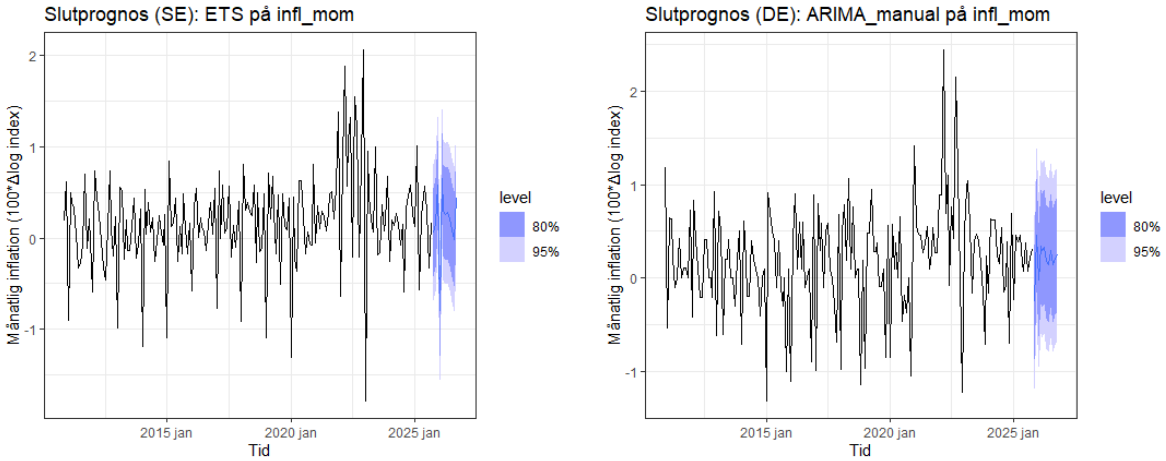

(a) Sverige

(b) Tyskland

Figur 4.8: Prognosen för den månatliga inflationen för länder.

Figur (a) visar slutprognosen för den månatliga inflationen i Sverige baserad på ETS-modellen, som identifierades som den bästa modellen i modelljämförelsen. Den svarta linjen representerar den observerade inflationen, medan den blå delen visar prognosen för de kommande 12 månaderna (H=12). Prognosen indikerar att inflationen förväntas fortsätta fluktuera kring en relativt stabil nivå nära sitt historiska medelvärde. De skuggade områdena visar prognosintervallen på 80% och 95%, vilka successivt blir bredare längre fram i prognosperioden. Detta speglar att osäkerheten i prognoserna ökar ju längre fram i tiden prognosen sträcker sig.

Figur (b) visar slutprognosen för den månatliga inflationen i Tyskland baserad på den manuellt specificerade ARIMA-modellen ($ARIMA(0,0,1)(1,0,0)_{12}$). Den historiska serien visas med svart linje, medan den blå delen visar prognosen för de kommande 12 månaderna. Prognosen antyder att inflationen fortsätter att variera kring en relativt stabil nivå utan någon tydlig långsiktig trend. Prognosintervallen på 80% och 95% blir gradvis bredare över prognoshorisonten, vilket är förväntat eftersom osäkerheten i prognosen ökar när prognosen sträcker sig längre in i framtiden.

5. Diskusion

I denna studie analyserades den månatliga inflationen i Sverige och Tyskland med hjälp av tidsseriemodeller baserade på HICP-indexdata från perioden 2010–2025. Resultaten visar att inflationen i båda länderna uppvisar tydliga säsongsmönster men saknar en statistiskt signifikant långsiktig trend under träningsperioden. Detta framgår både av STL-dekompositionen och av regressionsresultaten där trendkoefficienten inte var signifikant, medan flera säsongskomponenter var statistiskt signifikanta.

Vid modellidentifieringen visade ACF- och PACF-diagrammen att inflationserierna var stationära och uppvisade tydlig säsongskomponent med period 12 månader. Detta motiverade användningen av säsongsbaserade ARIMA-modeller. För Sverige identifierades modellen $ARIMA(0,0,1)(1,0,0)_{12}$ som en kandidatmodell, medan $ARIMA(0,0,1)(1,0,0)_{12}$ valdes för Tyskland. Dessa modeller jämfördes sedan med alternativa modeller såsom ETS, automatisk ARIMA och regressions-ARIMA.

Modelljämförelsen genomfördes med rullande korsvalidering där prognosfel beräknades med RMSE och MAE för prognoshorisonter upp till 12 månader. Resultaten visade att ETS-modellen gav den bästa prognosprestandan för Sverige, medan den manuellt specificerade ARIMA-modellen presterade bäst för Tyskland. Skillnaderna mellan modellerna var dock relativt små, vilket tyder på att flera modeller kan ge rimliga prognoser för dessa tidsserier.

Residualdiagnostiken visade att residualerna för båda modellerna i stor utsträckning uppvisar egenskaper som liknar vitt brus. För Sveriges ETS-modell låg de flesta autokorrelationerna inom konfidensgränserna och residualerna var ungefär symmetriskt fördelade kring noll. För Tysklands ARIMA-modell observerades liknande mönster, även om vissa mindre avvikelser förekom vid enstaka laggar. Detta indikerar att modellerna fångar huvuddelen av den systematiska strukturen i tidsserierna.

Testresultaten visade att prognosfelen generellt ökade med prognoshorisonten, vilket är ett vanligt fenomen inom tidsserieprognoser eftersom osäkerheten ökar över tiden. Samtidigt låg felmåtten på relativt stabila nivåer, vilket tyder på att de valda modellerna ger rimliga kortsiktiga prognoser för inflationen i båda länderna.

Det finns dock vissa begränsningar i studien. Analysen baseras enbart på HICP-data och inkluderar inte andra makroekonomiska faktorer som kan påverka inflationen, exempelvis energipriser, räntor eller arbetsmarknadsförhållanden. Vidare analyseras endast två länder, vilket begränsar generaliserbarheten av resultaten. Framtida studier skulle kunna inkludera fler ekonomiska variabler eller använda mer avancerade modeller, såsom multivariata tidsseriemodeller eller maskininlärningsbaserade prognosmetoder.

6. slutsat

Syftet med denna studie var att analysera och prognostisera inflationen i Sverige och Tyskland med hjälp av tidsseriemodeller baserade på HICP-data för perioden 2010–2025. Analysen visade att inflationen i båda länderna uppvisar tydliga säsongsmönster men saknar en statistiskt signifikant långsiktig trend under träningsperioden.

Flera tidsseriemodeller jämfördes, inklusive ETS, automatisk ARIMA, manuellt specificerad ARIMA samt regressions-ARIMA. Modellernas prognosprestanda utvärderades med hjälp av RMSE och MAE genom rullande korsvalidering. Resultaten visade att ETS-modellen gav den bästa prognosprestandan för Sverige, medan den manuellt specificerade modellen $ARIMA(0,0,1)(1,0,0)_{12}$ presterade bäst för Tyskland.

Residualdiagnostiken visade att båda modellerna uppvisade relativt god modellpassning, där residualerna i stor utsträckning kunde betraktas som vitt brus. Testresultaten bekräftade också att modellerna ger stabila prognoser för kortare prognoshorisonter, även om prognosfelen ökar något när prognoshorisonten blir längre.

Sammanfattningsvis visar studien att relativt enkla tidsseriemodeller kan ge användbara kortsiktiga prognoser för inflation baserad på HICP-data. Samtidigt indikerar resultaten att modellvalet kan skilja sig mellan länder beroende på tidsseriens struktur och dynamik.

Litteraturförteckning

[1] Ekonomifakta. (2024). *Hushållens konsumtion efter ändamål*. Svenskt Näringsliv. Tillgänglig på: https://www.ekonomifakta.se/diagram_och_tabeller/hushallens-konsumtion-efter-andamal_1210624.html (Hämtad 6 mars 2026).

[2] Statistiska centralbyrån (SCB). (2024). *Harmoniserat index för konsumentpriser (HIKP)*. Stockholm: Statistiska centralbyrån. Tillgänglig på: https://www.scb.se/vara-tjanster/index/konsumentpriser/harmoniserat-index-for-konsumentpriser-hikp/ (Hämtad 6 mars 2026).

[3] Ekonomifakta. (2024). *Inflation internationellt*. Svenskt Näringsliv. Tillgänglig på: https://www.ekonomifakta.se/sakomraden/makroekonomi/inflation-och-styrrantor/inflation-internationellt_1211540.html (Hämtad 6 mars 2026).

[4] International Monetary Fund (IMF). (2022). *Regional Economic Outlook: Europe – Fall 2022*. Washington, DC: International Monetary Fund. Tillgänglig på: https://www.imf.org/-/media/files/publications/reo/eur/2022/october/english/reoeur-fall-2022ch1final.pdf

[5] International Monetary Fund (IMF). (2024). *Inflation: Back to Basics*. Finance & Development. Tillgänglig på: https://www.imf.org/en/publications/fandd/issues/series/back-to-basics/inflation (Hämtad 6 mars 2026).

[6] Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3rd ed.). Melbourne: OTexts. Tillgänglig på: https://otexts.com/fpp3/

7. Bilaga

Den fullständiga R-koden för analysen finns tillgänglig på GitHub:
https://github.com/Tvths/Time_series_analysis_inflation/blob/main/TS_projekt.R.